

UNIVERSIDADE FEDERAL DO  
ESPÍRITO SANTO  
CENTRO DE CIÊNCIAS EXATAS  
DEPARTAMENTO DE ESTATÍSTICA

**Modelagem dos dados de 2013  
referentes às notificações de dengue  
no estado do Espírito Santo**

Segundo trabalho da disciplina de MLG ministrado  
pelo Prof. Dr. Saulo Morellato.

Alunos:

Orientador: Prof. Dr. Saulo Morellato

Abril  
2021

## Sumário

|          |  |          |
|----------|--|----------|
| <b>1</b> | <b>Descrição dos dados</b>                         | <b>2</b> |
| <b>2</b> | <b>Análise exploratória</b>                        | <b>3</b> |
| <b>3</b> | <b>Construção do modelo</b>                        | <b>5</b> |
| 3.1      | Modelo Poisson . . . . .                           | 5        |
| 3.1.1    | Definição do modelo . . . . .                      | 5        |
| 3.1.2    | Modelo considerando todas as covariáveis . . . . . | 5        |
| 3.1.3    | Modelo com seleção de covariáveis . . . . .        | 8        |
| 3.1.4    | Modelo com <code>_Offset_</code> . . . . .         | 12       |
| 3.1.5    | Interpretação e conclusões . . . . .               | 15       |
| 3.2      | Modelo Binomial Negativo . . . . .                 | 15       |
| 3.2.1    | Definição do modelo . . . . .                      | 15       |
| 3.2.2    | Modelo considerando todas covariáveis . . . . .    | 15       |
| 3.2.3    | Modelo com seleção de covariáveis . . . . .        | 17       |
| 3.2.4    | Modelo com <code>_Offset_</code> . . . . .         | 19       |
| 3.2.5    | Sobre a remoção de pontos influentes . . . . .     | 21       |
| 3.2.6    | Interpretação e conclusões . . . . .               | 29       |

# 1 Descrição dos dados

**IntCdAtBca** - Proporção de internações por condições sensíveis à Atenção Básica;

**CobCondSaud** - Cobertura de acompanhamento das condicionalidades de saúde do Programa Bolsa Família;

**CobAtBas** - Cobertura das equipes atenção básica municipal expresso em percentual da cobertura populacional alcançada pela Atenção Básica;

**temp** - temperatura média anual;

**temp\_p10** - percentil 10 das temperaturas durante o ano;

**temp\_p90** - percentil 90 das temperaturas durante o ano;

**precip** - precipitação pluviométrica acumulada anual;

**umid** - média anual da umidade relativa do ar;

**umid\_p10** - percentil 10 da umidade relativa do ar durante o ano;

**umid\_p90** - percentil 90 da umidade relativa do ar durante o ano;

**alt** - altitude da sede municipal;

**ifdm\_saude** - Índice Firjan de Desenvolvimento Municipal-IFDM para saúde;

**ifdm\_edu** - Índice Firjan de Desenvolvimento Municipal-IFDM para educação;

**ifdm\_emprend** - Índice Firjan de Desenvolvimento Municipal-IFDM de emprego e renda;

**cobveg** - índice de cobertura vegetal;

**expcoasteira** - índice de exposição costeira;

**ivc** - índice de vulnerabilidade climática;

**pobr** - proporção de pobres;

**ExpAnosEstud** - expectativa de anos de estudo;

**urb** - proporção da população que reside em zona urbana;

**menor15** - proporção da população com menos de 15 anos;

**maior65** - proporção da população com mais de 65 anos;

**adultos** - proporção da população entre 15 e 65 anos;

**pop** - população do município;

**area** - área do município;


**dens** - densidade populacional (poparea);

**id** - identificação;

**ano** - ano referente às informações; e

**dengue** - número de notificações municipais de dengue.

## 2 Análise exploratória



**Figura 1:** Notificações de dengue por municípios do estado do Espírito Santo.




Figura 2: Gráfico de correlação entre as covariáveis.

## 3 Construção do modelo

A primeira coisa a se fazer para termos um modelo de regressão é verificar se é possível utilizar a regressão linear, sendo que, nesse modelo a nossa variável resposta tem de apresentar uma distribuição aproximadamente normal.

Como temos a nossa variável de interesse como um dado de contagem, sendo esses dados com valores baixos, não é correto que ajustemos um modelo linear simples, sendo então necessário um modelo específico, no caso temos duas distribuições principais que podem ser melhores ajustes:

- Poisson
- Binomial Negativa

### 3.1 Modelo Poisson

Como vimos, a variável independente do modelo possui um formato que condiz com o de uma distribuição Poisson, temos, também que  $Y_i$  são independentes  $\forall i \leq n$ , onde cada unidade experimental é o município.

#### 3.1.1 Definição do modelo

Utilizando uma função de ligação logarítmica temos um modelo inicial utilizando todas as variáveis na forma sistemática abaixo

$$\log(\lambda_i) = \alpha + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_{26} x_{26i}$$

#### 3.1.2 Modelo considerando todas as covariáveis

Ajustando um modelo com todas as 26 covariáveis e realizando a seleção de variáveis pelo método `--AIC--` temos suas informações abaixo:

Call:

```
glm(formula = dengue ~ IntCdAtBca + CobCondSaud + CobAtencBsca +  
    temp_p10 + temp + temp_p90 + precip + umid_p10 + umid + umid_p90 +  
    alt + ifdm_saude + ifdm_edu + ifdm_emprend + cobveg + expcosteira +  
    ivc + Pobr + ExpAnosEstud + urb + menor15 + maior65 + pop +  
    area + dens, family = poisson, data = data)
```

Deviance Residuals:

| Min     | 1Q     | Median | 3Q    | Max    |
|---------|--------|--------|-------|--------|
| -76.799 | -8.593 | -3.737 | 2.188 | 80.479 |

```

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  5.625e+00  5.033e-01  11.177 < 2e-16 ***
IntCdAtBca   -1.841e-02  7.551e-04 -24.376 < 2e-16 ***
CobCondSaud  -1.122e-02  2.981e-04 -37.640 < 2e-16 ***
CobAtencBsca -8.239e-04  2.413e-04  -3.415 0.000637 ***
temp_p10      1.541e+00  2.921e-02  52.764 < 2e-16 ***
temp         -1.732e+00  4.962e-02 -34.911 < 2e-16 ***
temp_p90      4.375e-01  2.323e-02  18.835 < 2e-16 ***
precip        1.020e-03  2.390e-05  42.688 < 2e-16 ***
umid_p10     -3.788e-02  7.191e-03  -5.267 1.39e-07 ***
umid         -2.660e-01  1.490e-02 -17.858 < 2e-16 ***
umid_p90      3.570e-01  9.558e-03  37.357 < 2e-16 ***
alt          -1.478e-03  6.399e-05 -23.103 < 2e-16 ***
ifdm_saude   -4.640e-02  1.012e-03 -45.845 < 2e-16 ***
ifdm_edu      1.186e-02  1.532e-03   7.738 1.01e-14 ***
ifdm_emprend -1.883e-02  4.796e-04 -39.255 < 2e-16 ***
cobveg       -4.985e-03  2.213e-04 -22.522 < 2e-16 ***
expcosteira  -1.826e-02  2.070e-04 -88.190 < 2e-16 ***
ivc          -2.312e-02  3.151e-04 -73.368 < 2e-16 ***
Pobr         1.084e-01  2.277e-03  47.591 < 2e-16 ***
ExpAnosEstud 1.625e-01  1.060e-02  15.325 < 2e-16 ***
urb          4.995e-02  5.676e-04  87.989 < 2e-16 ***
menor15     -3.528e-01  5.361e-03 -65.821 < 2e-16 ***
maior65     -3.859e-01  6.691e-03 -57.672 < 2e-16 ***
pop          4.913e-06  5.292e-08  92.841 < 2e-16 ***
area         2.482e-04  7.988e-06  31.069 < 2e-16 ***
dens         2.018e-04  7.718e-06  26.147 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

    Null deviance: 630804  on 389  degrees of freedom
Residual deviance:  76437  on 364  degrees of freedom
AIC: 78440

Number of Fisher Scoring iterations: 6

```

Vemos que o desvio do resíduo é muito maior que seus graus de liberdade, o que indica um ajuste ruim. Para melhorar nosso modelo vamos reduzir sua dimensão, onde, pela análise descritiva, observamos que algumas covariáveis possuem baixa correlação com a variável resposta `_dengue_`,

por esse motivo, as retiramos do modelo, são essas variáveis `_ifdm_edu_` e `_area_`.

Para impedir multicolinearidade observamos altas correlações entre pares de covariáveis, sendo as mais altas descritas a seguir:

**Tabela 1:** Pares de covariáveis com as correlações mais altas identificadas:

| Variável 1          | Variável 2        | Correlação   |
|---------------------|-------------------|--------------|
| IntCdAtBca          | <b>ifdm_saude</b> | -0.77960350  |
| temp_p10            | <b>alt</b>        | -0.821314067 |
| temp_p10            | <b>temp</b>       | 0.993364738  |
| temp_p10            | <b>temp_p90</b>   | 0.946850236  |
| temp                | <b>temp_p90</b>   | 0.976276719  |
| <b>temp</b>         | <b>alt</b>        | -0.852298080 |
| <b>temp_p90</b>     | alt               | -0.884910605 |
| <b>precip</b>       | umid_p90          | 0.79257030   |
| umid_p10            | <b>umid</b>       | 0.86471582   |
| <b>umid</b>         | umid_p90          | 0.890202356  |
| umid_p90            | <b>ivc</b>        | -0.63608509  |
| <b>ifdm_emprend</b> | Pobr              | -0.62697421  |
| Pobr                | <b>adultos</b>    | -0.708001527 |
| menor15             | <b>maior65</b>    | -0.690958203 |
| menor15             | <b>adultos</b>    | -0.715345068 |
| pop                 | <b>dens</b>       | 0.78260681   |

Para nosso modelo escolhemos, então, seguir com a variável mais correlata com a variável resposta entre os pares da tabela acima, o que nos deixou com um modelo com as 15 variáveis abaixo:

- CobCondSaud
- CobAtencBsca
- temp\_p90
- precip
- umid
- ifdm\_saude
- ifdm\_emprend
- cobveg



- expcosteira
- ivc
- ExpAnosEstud
- urb
- maior65
- adultos
- dens

### 3.1.3 Modelo com seleção de covariáveis

Com o modelo descrito acima obtivemos, também com a seleção de variáveis pelo `AIC`, os seguintes resultados:

```
Call:
glm(formula = dengue ~ CobCondSaud + CobAtencBsca + temp_p90 +
    precip + umid + ifdm_saude + ifdm_emprend + cobveg + expcosteira +
    ivc + ExpAnosEstud + urb + maior65 + adultos + dens, family = poisson,
    data = data)
```

Deviance Residuals:

| Min     | 1Q     | Median | 3Q    | Max    |
|---------|--------|--------|-------|--------|
| -79.650 | -9.002 | -3.851 | 2.948 | 89.358 |

Coefficients:

|              | Estimate   | Std. Error | z value  | Pr(> z )   |
|--------------|------------|------------|----------|------------|
| (Intercept)  | -1.780e+01 | 3.944e-01  | -45.134  | <2e-16 *** |
| CobCondSaud  | -2.518e-02 | 2.579e-04  | -97.636  | <2e-16 *** |
| CobAtencBsca | -1.032e-02 | 1.740e-04  | -59.317  | <2e-16 *** |
| temp_p90     | 4.684e-01  | 5.163e-03  | 90.728   | <2e-16 *** |
| precip       | 1.003e-03  | 1.466e-05  | 68.392   | <2e-16 *** |
| umid         | 2.474e-02  | 2.743e-03  | 9.022    | <2e-16 *** |
| ifdm_saude   | -2.334e-02 | 7.268e-04  | -32.113  | <2e-16 *** |
| ifdm_emprend | -1.566e-02 | 4.009e-04  | -39.069  | <2e-16 *** |
| cobveg       | -4.818e-03 | 1.943e-04  | -24.799  | <2e-16 *** |
| expcosteira  | -2.103e-02 | 1.750e-04  | -120.217 | <2e-16 *** |
| ivc          | -2.860e-02 | 2.502e-04  | -114.313 | <2e-16 *** |
| ExpAnosEstud | 2.863e-01  | 8.079e-03  | 35.436   | <2e-16 *** |
| urb          | 3.204e-02  | 4.126e-04  | 77.669   | <2e-16 *** |
| maior65      | -1.330e-01 | 3.252e-03  | -40.898  | <2e-16 *** |

```

adultos      1.517e-01  3.737e-03  40.599  <2e-16 ***
dens         5.926e-04  6.096e-06  97.212  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

    Null deviance: 630804  on 389  degrees of freedom
Residual deviance: 101739  on 374  degrees of freedom
AIC: 103722

Number of Fisher Scoring iterations: 6

```

Note que em comparação com o modelo completo, em teoria, pioramos a qualidade do ajuste, porém, tiramos as multicolinearidades, que podem ser observadas na tabela com os VIFs de cada variável por modelo abaixo:

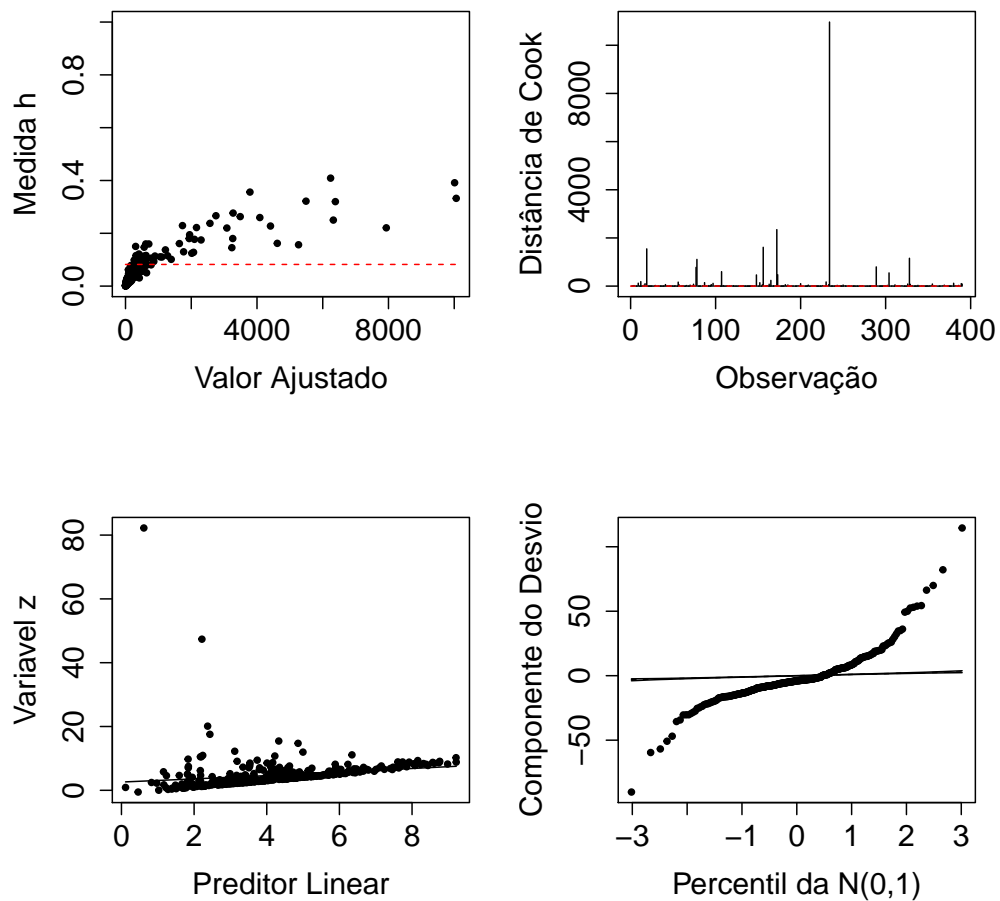
**Tabela 2:** Modelo com variáveis correlatas

|              | VIF        |
|--------------|------------|
| IntCdAtBca   | 3.340568   |
| CobCondSaud  | 4.516761   |
| CobAtencBsca | 4.193826   |
| temp_p10     | 113.647345 |
| temp         | 301.402079 |
| temp_p90     | 59.161914  |
| precip       | 17.075523  |
| umid_p10     | 90.809074  |
| umid         | 227.462163 |
| umid_p90     | 52.120415  |
| alt          | 3.903644   |
| ifdm_saude   | 6.531280   |
| ifdm_edu     | 9.642008   |
| ifdm_emprend | 4.907702   |
| cobveg       | 7.685869   |
| expcosteira  | 9.610107   |
| ivc          | 8.212447   |
| Pobr         | 15.043009  |
| ExpAnosEstud | 3.831969   |
| urb          | 7.619431   |
| menor15      | 27.804045  |
| maior65      | 17.626240  |
| pop          | 11.892503  |
| area         | 4.290132   |
| dens         | 17.308483  |

**Tabela 3:** Modelo sem variáveis correlatas

|              | VIF       |
|--------------|-----------|
| CobCondSaud  | 3.380583  |
| CobAtencBsca | 2.412786  |
| temp_p90     | 2.934455  |
| precip       | 6.425093  |
| umid         | 7.753469  |
| ifdm_saude   | 3.234629  |
| ifdm_emprend | 3.295120  |
| cobveg       | 6.045962  |
| expcoasteira | 7.002723  |
| ivc          | 4.899843  |
| ExpAnosEstud | 2.546300  |
| urb          | 3.872085  |
| maior65      | 4.019939  |
| adultos      | 5.614155  |
| dens         | 10.987268 |

Seguimos, agora, para a análise do nosso modelo sem as variáveis correlatas, que nos dá os gráficos abaixo:



**Figura :** Gráficos de diagnóstico para o modelo sem `_offset_`.

Como é possível observar pelos gráficos da *Figura*, principalmente pelo gráfico de envelope dos resíduos, temos um modelo superdisperso, o que tentaremos resolver acrescentando um `_offset_`.

### 3.1.4 Modelo com `_Offset_`

Para adicionarmos um dado `_offset_` no modelo vemos que ele pode ser a variável `_pop_`, que indica uma alta variabilidade do tamanho das populações nos municípios. Segue o modelo:

```
Call:
glm(formula = dengue ~ CobCondSaud + CobAtencBsca + temp_p90 +
    precip + umid + ifdm_saude + ifdm_emprend + cobveg + expcosteira +
    ivc + ExpAnosEstud + urb + maior65 + adultos + dens + offset(log(pop)),
    family = poisson, data = data)
```

Deviance Residuals:

| Min     | 1Q     | Median | 3Q    | Max    |
|---------|--------|--------|-------|--------|
| -76.558 | -8.836 | -4.680 | 0.753 | 71.536 |

Coefficients:

|              | Estimate   | Std. Error | z value | Pr(> z ) |     |
|--------------|------------|------------|---------|----------|-----|
| (Intercept)  | -3.457e+01 | 3.948e-01  | -87.546 | <2e-16   | *** |
| CobCondSaud  | -9.838e-03 | 2.650e-04  | -37.124 | <2e-16   | *** |
| CobAtencBsca | 5.798e-03  | 1.979e-04  | 29.294  | <2e-16   | *** |
| temp_p90     | 4.254e-01  | 5.316e-03  | 80.033  | <2e-16   | *** |
| precip       | 9.829e-04  | 1.445e-05  | 68.036  | <2e-16   | *** |
| umid         | 1.046e-01  | 2.729e-03  | 38.321  | <2e-16   | *** |
| ifdm_saude   | -3.633e-02 | 7.469e-04  | -48.638 | <2e-16   | *** |
| ifdm_emprend | -4.018e-02 | 4.172e-04  | -96.307 | <2e-16   | *** |
| cobveg       | -3.371e-03 | 2.019e-04  | -16.694 | <2e-16   | *** |
| expcosteira  | -1.374e-02 | 1.734e-04  | -79.256 | <2e-16   | *** |
| ivc          | -1.743e-02 | 2.494e-04  | -69.905 | <2e-16   | *** |
| ExpAnosEstud | 1.261e-01  | 8.573e-03  | 14.714  | <2e-16   | *** |
| urb          | 1.829e-02  | 4.362e-04  | 41.940  | <2e-16   | *** |
| maior65      | 2.850e-02  | 3.273e-03  | 8.708   | <2e-16   | *** |
| adultos      | 1.820e-01  | 4.011e-03  | 45.363  | <2e-16   | *** |
| dens         | 6.176e-05  | 6.065e-06  | 10.183  | <2e-16   | *** |

---

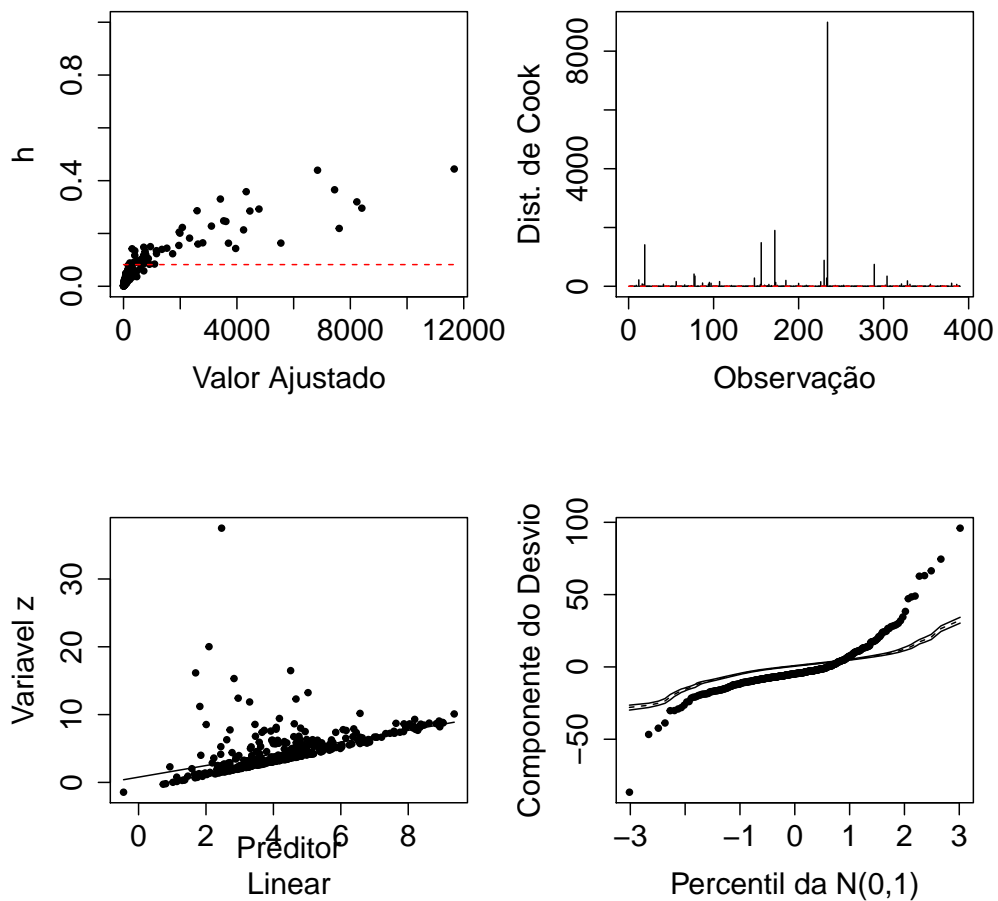
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 180512 on 389 degrees of freedom  
Residual deviance: 81585 on 374 degrees of freedom  
AIC: 83568

Number of Fisher Scoring iterations: 6

Vemos que, ainda que tenhamos adicionado o dado `_offset_`, continuamos com um desvio do resíduo super alto, o que significa que o ajuste segue impróprio para o modelo, o que vamos confirmar com a análise dos gráficos do modelo:



**Figura :** Gráficos de diagnóstico para o modelo com `_offset_`.

### 3.1.5 Interpretação e conclusões

Pudemos observar que, mesmo manipulando nosso modelo, continuamos com um ajuste ruim, visto que temos um desvio residual muito maior que os graus de liberdade. Outro indício disso é a sobredispersão observada no gráfico de envelope, o que podemos imaginar que ocorreria, uma vez que temos a média da nossa variável resposta dengue consideravelmente diferente da sua variância, o que não deveria ocorrer, uma vez que a distribuição de Poisson teórica possui média e variância iguais.

Tais constatações nos levam a descartar o modelo Poisson e tentar o ajuste por um modelo Binomial Negativo.

## 3.2 Modelo Binomial Negativo

O modelo Binomial Negativo por definição não é MLG, entretanto, possui características muito semelhantes e possui uma boa capacidade de capturar um efeito  $E(Y_i) < Var(Y_i)$ . Que é exatamente o problema encontrado acima.

### 3.2.1 Definição do modelo

### 3.2.2 Modelo considerando todas covariáveis

Ajustando um modelo com todas as 26 covariáveis e realizando a seleção de variáveis pelo método AIC temos suas informações abaixo:

Call:

```
glm.nb(formula = dengue ~ CobAtencBsca + temp_p10 + temp + temp_p90 +  
      umid_p10 + umid + alt + ifdm_edu + ifdm_emprend + ivc + urb +  
      menor15 + maior65 + pop + area, data = dados, control = glm.control(maxit =  
      init.theta = 0.6787461656, link = log)
```

Deviance Residuals:

| Min     | 1Q      | Median  | 3Q     | Max    |
|---------|---------|---------|--------|--------|
| -2.4329 | -1.1783 | -0.5526 | 0.1411 | 2.7976 |

Coefficients:

|              | Estimate   | Std. Error | z value | Pr(> z )     |
|--------------|------------|------------|---------|--------------|
| (Intercept)  | 5.133e+00  | 6.101e+00  | 0.841   | 0.400165     |
| CobAtencBsca | -1.062e-02 | 3.778e-03  | -2.811  | 0.004932 **  |
| temp_p10     | 2.490e+00  | 3.730e-01  | 6.677   | 2.44e-11 *** |
| temp         | -2.995e+00 | 6.341e-01  | -4.723  | 2.33e-06 *** |
| temp_p90     | 5.525e-01  | 3.284e-01  | 1.682   | 0.092510 .   |
| umid_p10     | -5.062e-01 | 7.104e-02  | -7.126  | 1.03e-12 *** |



```

umid      5.038e-01  9.732e-02   5.176 2.26e-07 ***
alt       -2.248e-03  5.793e-04  -3.881 0.000104 ***
ifdm_edu   4.220e-02  1.823e-02   2.315 0.020639 *
ifdm_emprend -1.557e-02  7.711e-03  -2.019 0.043449 *
ivc        -7.831e-03  4.752e-03  -1.648 0.099358 .
urb        4.974e-02  4.531e-03  10.978 < 2e-16 ***
menor15    -1.197e-01  6.162e-02  -1.943 0.052063 .
maior65    -1.768e-01  8.322e-02  -2.125 0.033580 *
pop        6.195e-06  1.003e-06   6.179 6.47e-10 ***
area       5.633e-04  1.368e-04   4.118 3.82e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(0.6787) family taken to be 1)

Null deviance: 1482.16  on 389  degrees of freedom
Residual deviance: 457.31  on 374  degrees of freedom
AIC: 3971.4

Number of Fisher Scoring iterations: 1

      Theta:  0.6787
    Std. Err.:  0.0460

2 x log-likelihood:  -3937.3930

```

Como aconteceu com o Modelo Poisson, é possível perceber, com base no desvio residual que o ajuste é ruim. Para corrigir isso, faremos o mesmo que foi feito com o Modelo Poisson, ou seja, usaremos as 15 variáveis mais correlatadas com a variável resposta, sendo elas:

- CobCondSaud
- CobAtencBsca
- temp\_p90
- precip
- umid
- ifdm\_saude
- ifdm\_emprend

- cobveg
- expcosteira
- ivc
- ExpAnosEstud
- urb
- maior65
- adultos
- dens

### 3.2.3 Modelo com seleção de covariáveis

Com o modelo descrito acima obtivemos, também com a seleção de variáveis pelo `_AIC_`, os seguintes resultados:

```
Call:
glm.nb(formula = dengue ~ CobAtencBsca + temp_p90 + ifdm_saude +
  ifdm_emprend + cobveg + urb + maior65 + pop, data = dados_2013,
  control = glm.control(maxit = 50), init.theta = 0.9549042419,
  link = log)
```

Deviance Residuals:

| Min     | 1Q      | Median  | 3Q     | Max    |
|---------|---------|---------|--------|--------|
| -2.2211 | -1.1597 | -0.5190 | 0.5277 | 1.7196 |

Coefficients:

|              | Estimate   | Std. Error | z value | Pr(> z ) |     |
|--------------|------------|------------|---------|----------|-----|
| (Intercept)  | -9.909e+00 | 2.488e+00  | -3.983  | 6.8e-05  | *** |
| CobAtencBsca | -1.731e-02 | 6.116e-03  | -2.830  | 0.00466  | **  |
| temp_p90     | 2.597e-01  | 1.003e-01  | 2.590   | 0.00960  | **  |
| ifdm_saude   | 3.859e-02  | 1.628e-02  | 2.371   | 0.01773  | *   |
| ifdm_emprend | 1.990e-02  | 1.385e-02  | 1.436   | 0.15091  |     |
| cobveg       | -1.410e-02 | 4.493e-03  | -3.139  | 0.00170  | **  |
| urb          | 5.752e-02  | 8.886e-03  | 6.473   | 9.6e-11  | *** |
| maior65      | 2.543e-01  | 8.215e-02  | 3.095   | 0.00197  | **  |
| pop          | 4.355e-06  | 1.837e-06  | 2.371   | 0.01776  | *   |

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

```
(Dispersion parameter for Negative Binomial(0.9549) family taken to be 1)
```

```
Null deviance: 387.550  on 77  degrees of freedom  
Residual deviance:  89.209  on 69  degrees of freedom  
AIC: 912.9
```

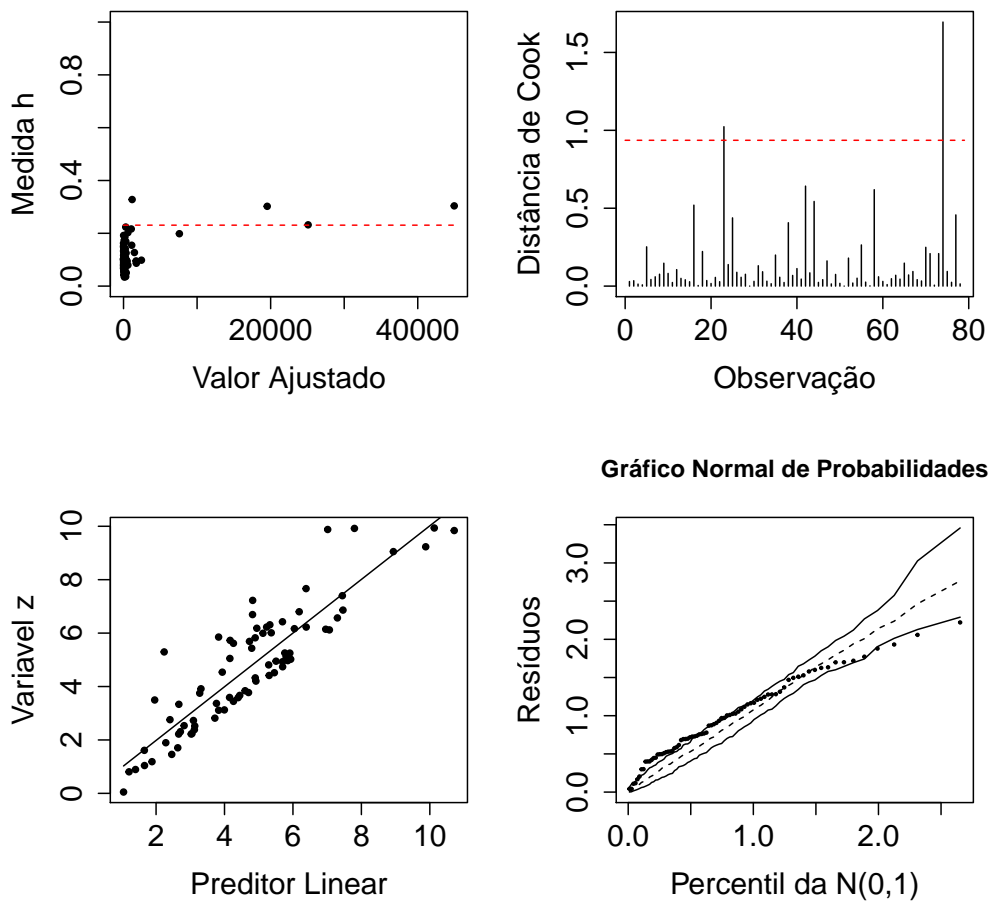
```
Number of Fisher Scoring iterations: 1
```

```
Theta:  0.955  
Std. Err.:  0.142
```

```
2 x log-likelihood:  -892.899
```

Perceba que, com a escolha de variáveis acima, melhoramos bastante o ajuste do modelo. Gerando os gráficos para o modelo acima, obtemos:

```
Negative binomial model (using MASS package)
```



### 3.2.4 Modelo com `_Offset_`

Agora, colocando a variável `_pop_` como `_Offset_`

Call:

```
glm.nb(formula = dengue ~ temp_p90 + umid + cobveg + urb + maior65 +
  adultos + offset(log(pop)), data = dados_2013, control = glm.control(maxit = 100,
  init.theta = 1.108820464, link = log)
```

Deviance Residuals:

| Min     | 1Q      | Median  | 3Q     | Max    |
|---------|---------|---------|--------|--------|
| -2.4896 | -1.0525 | -0.4003 | 0.4286 | 1.8971 |

Coefficients:

|             | Estimate   | Std. Error | z value | Pr(> z )     |
|-------------|------------|------------|---------|--------------|
| (Intercept) | -22.743600 | 6.472959   | -3.514  | 0.000442 *** |

```

temp_p90      0.340296    0.091139    3.734 0.000189 ***
umid          -0.131944    0.085253   -1.548 0.121702
cobveg        -0.012231    0.004026   -3.038 0.002381 **
urb           0.041645    0.006909    6.028 1.66e-09 ***
maior65       0.303516    0.071226    4.261 2.03e-05 ***
adultos       0.205808    0.080866    2.545 0.010926 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(1.1088) family taken to be 1)

    Null deviance: 185.528  on 77  degrees of freedom
Residual deviance:  87.661  on 71  degrees of freedom
AIC: 895.02

Number of Fisher Scoring iterations: 1

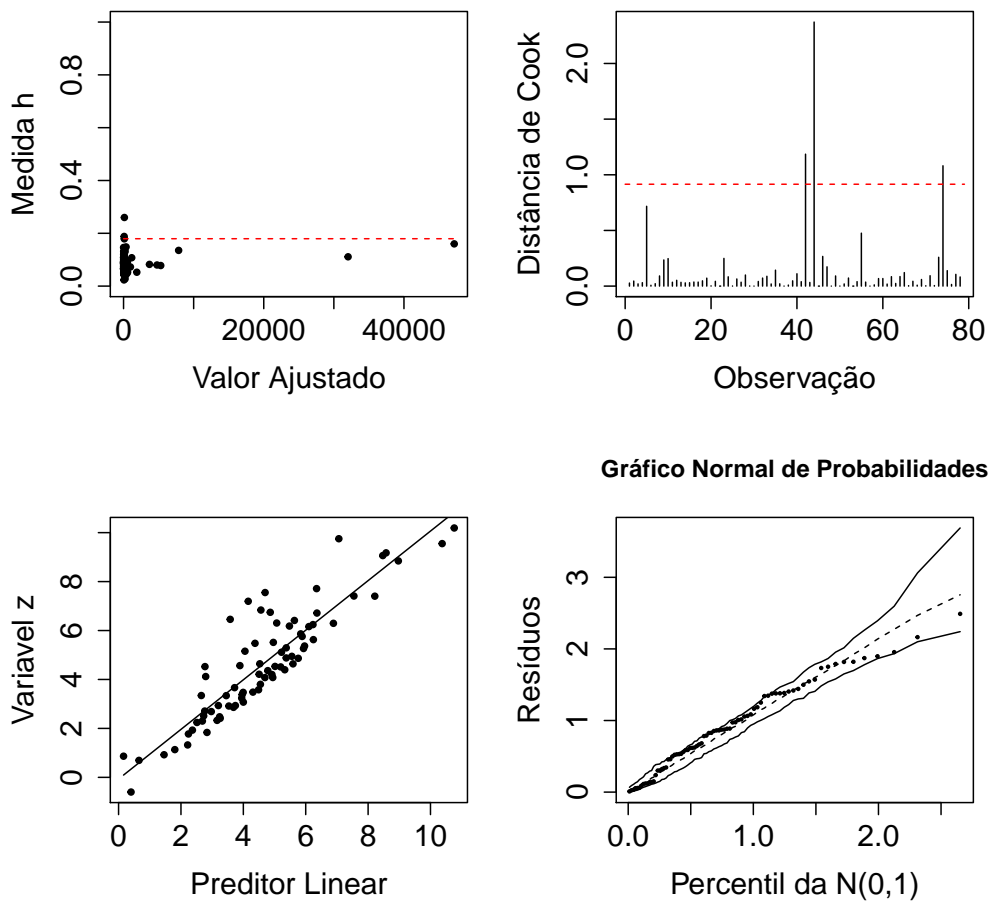
            Theta:  1.109
         Std. Err.:  0.168

2 x log-likelihood:  -879.015

```

A escolha de deixar a variável `_pop_` como `_Offset_` melhorou o ajuste do modelo, visto que o desvio residual se aproximou um pouco mais dos graus de liberdade, abaixo, temos os gráficos do modelo com `_Offset_`:

Negative binomial model (using MASS package)



### 3.2.5 Sobre a remoção de pontos influentes

Usando a função `identify`, identificamos pontos influentes, entretanto, preferimos por não remove-los, já que em nosso subset temos apenas 78 linhas. Abaixo, alguns resultados que obtivemos na remoção de alguns pontos influentes:

Call:

```
glm.nb(formula = dengue ~ CobAtencBsca + temp_p90 + cobveg +
  urb + maior65 + adultos + offset(log(pop)), data = dados_2013_1,
  control = glm.control(maxit = 50), init.theta = 1.198029355,
  link = log)
```

Deviance Residuals:

| Min     | 1Q      | Median  | 3Q     | Max    |
|---------|---------|---------|--------|--------|
| -2.5633 | -1.1437 | -0.4232 | 0.3603 | 2.2826 |

Coefficients:

|              | Estimate   | Std. Error | z value | Pr(> z ) |     |
|--------------|------------|------------|---------|----------|-----|
| (Intercept)  | -34.285911 | 4.970307   | -6.898  | 5.27e-12 | *** |
| CobAtencBsca | -0.008437  | 0.005242   | -1.609  | 0.10753  |     |
| temp_p90     | 0.366814   | 0.087693   | 4.183   | 2.88e-05 | *** |
| cobveg       | -0.008306  | 0.003977   | -2.089  | 0.03674  | *   |
| urb          | 0.035152   | 0.006475   | 5.429   | 5.66e-08 | *** |
| maior65      | 0.298576   | 0.068929   | 4.332   | 1.48e-05 | *** |
| adultos      | 0.228635   | 0.070673   | 3.235   | 0.00122  | **  |

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

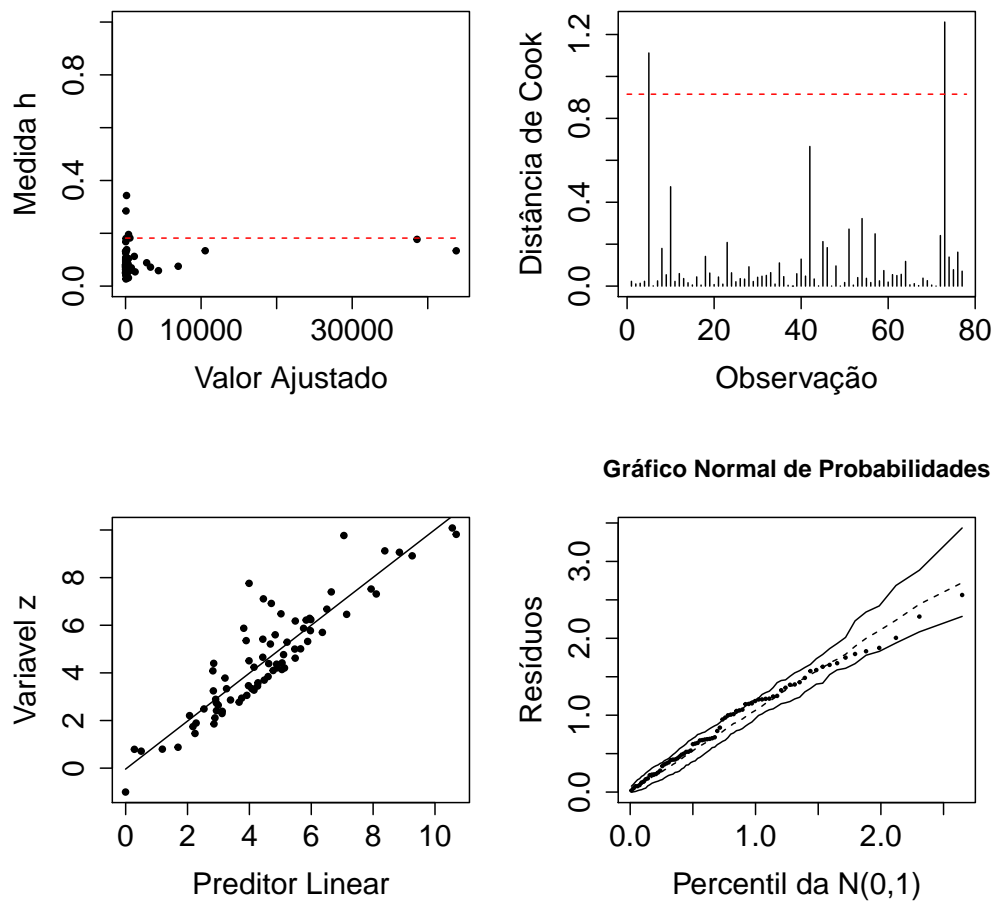
(Dispersion parameter for Negative Binomial(1.198) family taken to be 1)

Null deviance: 196.137 on 76 degrees of freedom  
Residual deviance: 85.601 on 70 degrees of freedom  
AIC: 872.8

Number of Fisher Scoring iterations: 1

Theta: 1.198  
Std. Err.: 0.184

2 x log-likelihood: -856.795  
Negative binomial model (using MASS package)



**Figura :** Gráficos de diagnóstico para uma remoção.

Call:

```
glm.nb(formula = dengue ~ CobAtencBsca + temp_p90 + cobveg +
  urb + maior65 + adultos + offset(log(pop)), data = dados_2013_1,
  control = glm.control(maxit = 50), init.theta = 1.253312012,
  link = log)
```

Deviance Residuals:

| Min     | 1Q      | Median  | 3Q     | Max    |
|---------|---------|---------|--------|--------|
| -2.5909 | -1.1703 | -0.4457 | 0.3656 | 2.4699 |

Coefficients:

|              | Estimate   | Std. Error | z value | Pr(> z )     |
|--------------|------------|------------|---------|--------------|
| (Intercept)  | -31.113766 | 4.886489   | -6.367  | 1.92e-10 *** |
| CobAtencBsca | -0.009940  | 0.005143   | -1.933  | 0.05326 .    |



```

temp_p90      0.366527    0.085911    4.266 1.99e-05 ***
cobveg       -0.007076    0.003907   -1.811  0.07013  .
urb           0.032614    0.006369    5.121 3.05e-07 ***
maior65       0.340456    0.068831    4.946 7.56e-07 ***
adultos       0.179964    0.069549    2.588  0.00967  **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(1.2533) family taken to be 1)

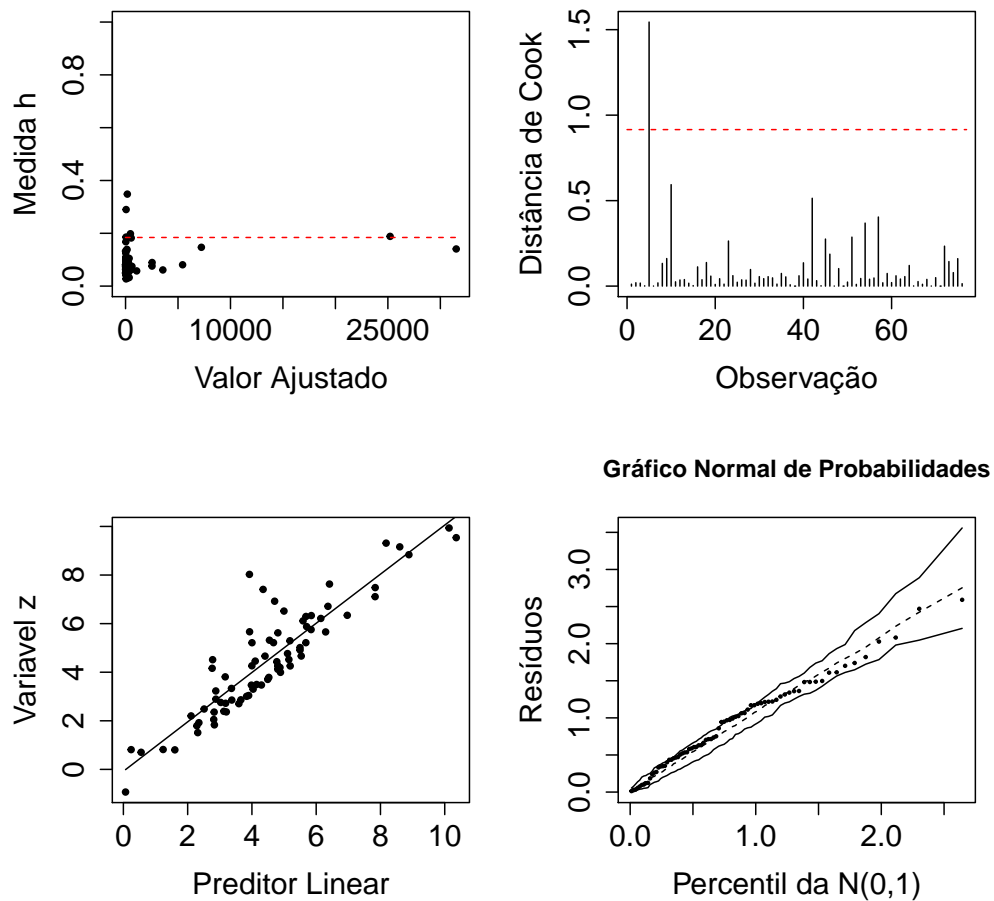
    Null deviance: 191.231  on 75  degrees of freedom
Residual deviance:  84.312  on 69  degrees of freedom
AIC: 849.46

Number of Fisher Scoring iterations: 1

            Theta:  1.253
        Std. Err.:  0.196

2 x log-likelihood:  -833.462
Negative binomial model (using MASS package)

```



**Figura :** Gráficos de diagnóstico para duas remoção.

```
Call:
glm.nb(formula = dengue ~ temp_p90 + ifdm_emprend + urb + maior65 +
        offset(log(pop)), data = dados_2013_1, control = glm.control(maxit = 50),
        init.theta = 1.325796543, link = log)
```

Deviance Residuals:

| Min     | 1Q      | Median  | 3Q     | Max    |
|---------|---------|---------|--------|--------|
| -2.4953 | -1.0957 | -0.4375 | 0.4739 | 2.1774 |

Coefficients:

|              | Estimate   | Std. Error | z value | Pr(> z )     |
|--------------|------------|------------|---------|--------------|
| (Intercept)  | -20.622947 | 2.066536   | -9.979  | < 2e-16 ***  |
| temp_p90     | 0.306737   | 0.078022   | 3.931   | 8.44e-05 *** |
| ifdm_emprend | 0.029342   | 0.010969   | 2.675   | 0.00748 **   |

```

urb          0.034786    0.006468    5.378 7.53e-08 ***
maior65      0.360962    0.070642    5.110 3.23e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(1.3258) family taken to be 1)

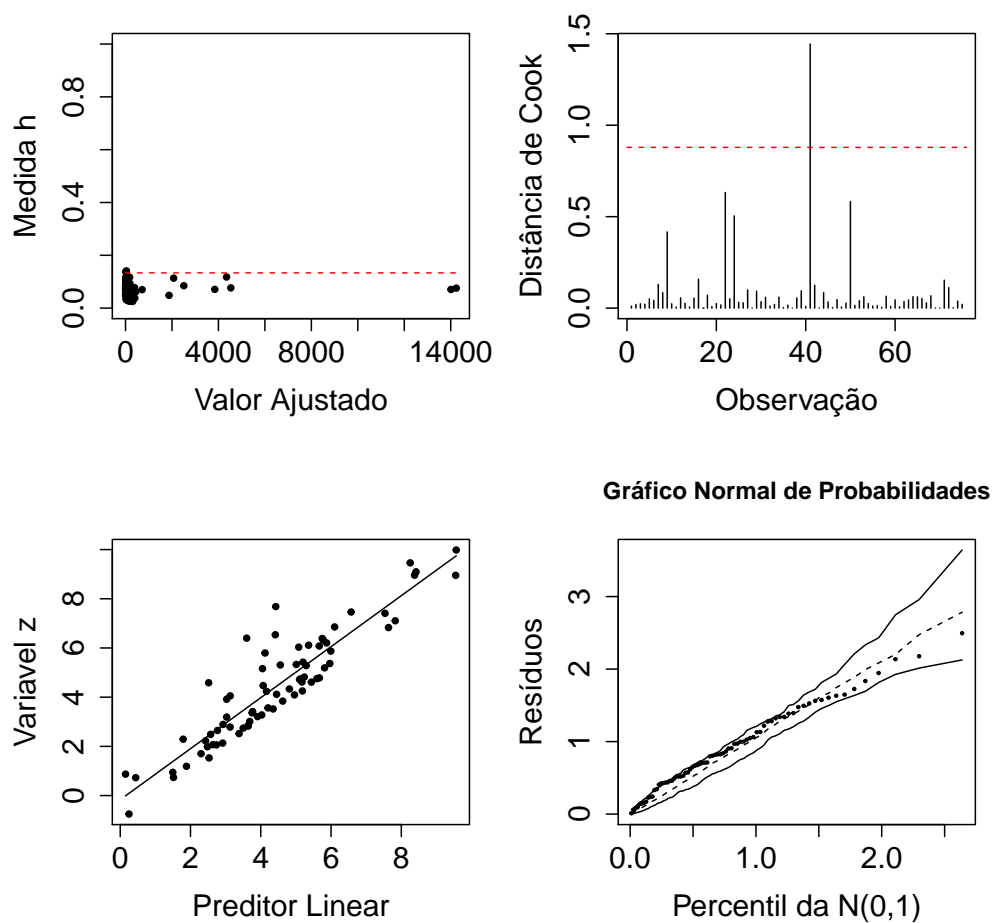
    Null deviance: 198.864  on 74  degrees of freedom
Residual deviance:  82.865  on 70  degrees of freedom
AIC: 826.49

Number of Fisher Scoring iterations: 1

            Theta:  1.326
        Std. Err.:  0.210

2 x log-likelihood:  -814.486
Negative binomial model (using MASS package)

```



**Figura :** Gráficos de diagnóstico para tres remoções.

```
Call:
glm.nb(formula = dengue ~ temp_p90 + ifdm_emprend + urb + maior65 +
  offset(log(pop)), data = dados_2013_1, control = glm.control(maxit = 50),
  init.theta = 1.392919725, link = log)
```

Deviance Residuals:

| Min     | 1Q      | Median  | 3Q     | Max    |
|---------|---------|---------|--------|--------|
| -2.4316 | -1.1139 | -0.2938 | 0.4929 | 2.4241 |

Coefficients:

|              | Estimate  | Std. Error | z value | Pr(> z )     |
|--------------|-----------|------------|---------|--------------|
| (Intercept)  | -19.31992 | 2.03987    | -9.471  | < 2e-16 ***  |
| temp_p90     | 0.26653   | 0.07660    | 3.479   | 0.000503 *** |
| ifdm_emprend | 0.02567   | 0.01081    | 2.374   | 0.017616 *   |

```

urb          0.04005    0.00651    6.152 7.65e-10 ***
maior65      0.31144    0.07106    4.383 1.17e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(1.3929) family taken to be 1)

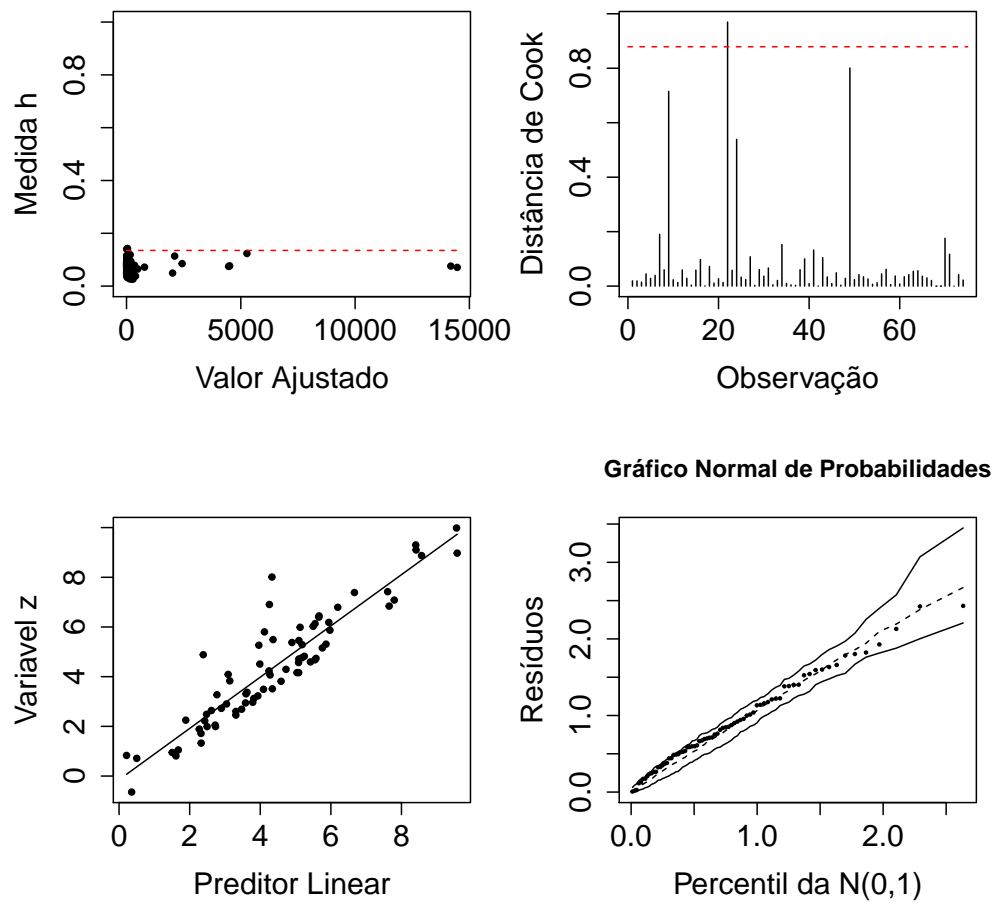
    Null deviance: 207.600  on 73  degrees of freedom
Residual deviance:  81.419  on 69  degrees of freedom
AIC: 809.81

Number of Fisher Scoring iterations: 1

            Theta:  1.393
         Std. Err.:  0.224

2 x log-likelihood:  -797.807
Negative binomial model (using MASS package)

```



**Figura :** Gráficos de diagnóstico para quatro remoções.

### 3.2.6 Interpretação e conclusões